

CS 430 / INFO 430

Information Retrieval

Lecture 07

String Processing

Course administration

Query Language

لغة الاستعلام

A **query language** defines the syntax and the semantics of the queries in a given search system. Factors to consider in designing a query language include:

تحدد لغة الاستعلام بناء الجملة ودلالاتها في نظام بحث معين. تشمل العوامل التي يجب مراعاتها عند تصميم لغة الاستعلام ما يلي:

Service needs

- What are the characteristics of the documents being searched? What need does the service satisfy?

احتياجات الخدمة

- ما هي خصائص الوثائق التي يتم البحث عنها ما الحاجة التي تلبّيها الخدمة

Human factors

- Are the users trained or untrained or both? What is the trade-off between power of the language and easy of learning?

عوامل بشرية

- هل المستخدمون مدربون أم غير مدربين أم كلاهما ما هي المقايضة بين قوة اللغة وسهولة التعلم

Efficiency

- Can the search system process all queries efficiently?

نجاعة

- هل يمكن لنظام البحث معالجة جميع الاستفسارات بكفاءة

Query Languages

لغات الاستعلام

Traditionally, query languages have fallen into two camps:

تقليديا تدرج لغات الاستعلام في معسكرين:

- (a) Powerful and expressive languages which are not easily readable nor writable by non-experts (e.g. SQL and XQuery).
- (b) Simple and intuitive languages not powerful enough to express complex concepts (e.g. CCL or Google's query language).

Query Languages: the Common Query Language لغات الاستعلام: لغة الاستعلام الشائعة

The Common Query Language: a formal language for queries to information retrieval systems such as web indexes, bibliographic catalogs and museum collection information.

لغة الاستعلام الشائعة: لغة رسمية للاستعلامات الخاصة بأنظمة استرجاع المعلومات مثل فهارس الويب والكتالوجات الببليوغرافية ومعلومات جمع المتاحف.

Objective: human readable and human writable; intuitive while maintaining the expressiveness of more complex languages.

لهدف: مقروء بشري وقابل للكتابة بديهية مع الحفاظ على التعبيرية للغات أكثر تعقيداً.

Supports:

يدعم:

- Full text searching
- Boolean operators
- Fielded searching

• البحث عن النص الكامل

العوامل المنطقية

• البحث الميداني

The Common Query Language

لغة الاستعلام الشائعة

The Common Query Language is maintained by the Z39.50 International Maintenance Agency at the Library of Congress.

يتم صيانة لغة الاستعلام المشتركة بواسطة وكالة الصيانة الدولية Z39.50 في مكتبة الكونغرس.

<http://www.loc.gov/z3950/agency/zing/cql/>

The following examples are taken from the CQL Tutorial, A Gentle Introduction to CQL.

الأمثلة التالية مأخوذة من دروس CQL مقدمة لطيفة لـ CQL.

The Common Query Language: Examples

لغة الاستعلام الشائعة: أمثلة

Simple queries

استفسارات بسيطة

dinosaur
comp.sources.misc
"complete dinosaur"
"the complete dinosaur"
"ext->u.generic"
"and"

Booleans

قيمة منطقية

dinosaur or bird
dinosaur and bird or dinobird
(bird or dinosaur) and (feathers or scales)
"feathered dinosaur" and (yixian or jehol)
(((a and b) or (c not d) not (e or f and g)) and h not i) or j

The Common Query Language: Examples

لغة الاستعلام الشائعة: أمثلة

Indexes [fielded searching]

فهارس [بحث ميداني]

```
title = dinosaur
title = ((dinosaur and bird) or dinobird)
dc.title = saurischia
bath.title="the complete dinosaur"
srw.serverChoice=foo
srw.resultSet=bar
```

Index-set mapping [definition of fields]

تعيين مجموعة الفهرس [تعريف الحقول]

```
>dc=http://www.loc.gov/srw/index-sets/dc
...
dc.title=dinosaur and dc.author=farlow
```


The Common Query Language: Examples

لغة الاستعلام الشائعة: أمثلة

Proximity

The prox operator:

prox/relation/distance/unit/ordering

Examples:

complete prox dinosaur [adjacent]

(caudal or dorsal) prox vertebra

ribs prox//5 chevrons [near 5]

ribs prox//0/sentence chevrons [same sentence]

ribs prox/>/0/paragraph chevrons [not adjacent]

The Common Query Language: Examples

لغة الاستعلام الشائعة: أمثلة

Relations

year > 1998

title all "complete dinosaur" [all terms in title]

title any "dinosaur bird reptile" [any term in title]

title exact "the complete dinosaur"

publicationYear < 1980

numberOfWheels <= 3

numberOfPlates = 18

lengthOfFemur > 2.4

bioMass >= 100

numberOfToes <> 3

The Common Query Language: Examples

لغة الاستعلام الشائعة: أمثلة

Relation Modifiers

title all/stem "complete dinosaur"

title any/relevant "dinosaur bird reptile"

title exact/fuzzy "the complete dinosaur"

author =/fuzzy tailor

The implementations of relevant and fuzzy are not defined by the query language.

لا يتم تعريف عمليات التنفيذ ذات الصلة والغامض من خلال لغة الاستعلام.

The Common Query Language: Examples

لغة الاستعلام الشائعة: أمثلة

Pattern Matching

dinosaur* [zero or more characters]

*sauria

man?raptor [exactly one character]

man?raptor*

"the comp*saur"

char* [literal "*"]

Word Anchoring

title="^the complete dinosaur" [beginning of field]

author="bakker^" [end of field]

author all "^kernighan ritchie"

author any "^kernighan ^ritchie ^thompson"

The Common Query Language: Examples

لغة الاستعلام الشائعة: أمثلة

A complete example

مثال كامل

```
dc.author=(kern* or ritchie) and  
(bath.title exact "the c programming language" or  
dc.title=elements prox///4 dc.title=programming) and  
subject any/relevant "style design analysis"
```

Find records whose author (in the Dublin Core sense) includes either a word beginning kern or the word ritchie, and which have either the exact title (in the sense of the Bath profile) the c programming language or a title containing the words elements and programming not more the four words apart, and whose subject is relevant to one or more of the words style, design or analysis.

ابحث عن التسجيلات التي يتضمن مؤلفها (بمعنى دبلن كور) إما كلمة تبدأ ب kern أو الكلمة والتي تحتوي إما على العنوان الدقيق (بمعنى ملف تعريف باث) لغة البرمجة c أو ritchie عنوان يحتوي على عناصر الكلمات و البرمجة ليس أكثر من أربع كلمات متباعدة وموضوعها وثيق الصلة بوحدة أو أكثر من الكلمات أسلوب أو تصميم أو تحليل.

Query Languages: Regular Expressions

لغات الاستعلام: التعبيرات العادية

Regular expression:

A pattern built up by simple strings (which are matched as substrings) and operators

تعبير عادي:

نمط تم إنشاؤه بواسطة سلاسل بسيطة (تتوافق مع سلاسل فرعية) وعوامل تشغيل

Union: If e_1 and e_2 are regular expressions, then $(e_1 \mid e_2)$ matches whatever matches e_1 or e_2 .

إذا كانت e_1 و e_2 عبارة عن تعبيرات عادية فإن $(e_1 \mid e_2)$ تتطابق مع أي a كان يتطابق مع e_1 أو e_2 .

Concatenation: If e_1 and e_2 are regular expressions, the occurrences of $(e_1 e_2)$ are formed by the occurrences of e_1 followed immediately by e_2 .

التسلسل: إذا كان e_1 و e_2 تعبيرين عاديين فإن تكرارات $(e_1 e_2)$ تتشكل بواسطة تكرارات e_1 متبوعة مباشرة بـ e_2 .

Repetition: If e is a regular expression, then e^* matches a sequence of zero or more contiguous occurrences of e .

تكرار: إذا كان e تعبير عادي a فإن e^* يطابق تسلسل a من الصفر أو أكثر من تكرارات متقاربة لـ e .

Regular Expression Examples

أمثلة على التعبير العادي

(wild card) matches "wild card"

travell*ed matches "traveled" or "travelled",
but not "traveed"

192 (0 | 1 | 2 | 3 | 4 | 5) matches any string in
the range "1920" to "1925"

Techniques for processing regular
expressions are
taught in CS 381 and CS 481.

تقنيات معالجة التعبيرات العادية هي
تدرس في CS 381 و CS 481.

Regular Expressions in Java

التعبيرات العادية في Java

Package `java.util.regex`

الحزمة `java.util.regex`

Classes for matching character sequences against patterns specified by regular expressions.

فئات مطابقة تسلسل الأحرف مقابل الأنماط المحددة بواسطة التعبيرات العادية

An instance of the `Pattern` class represents a regular expression that is specified in string form in a syntax similar to that used by Perl.

يمثل مثيل فئة `Pattern` تعبيراً عادياً محدداً في شكل سلسلة في صيغة مشابهة لتلك المستخدمة بواسطة Perl.

Instances of the `Matcher` class are used to match character sequences against a given pattern.

تستخدم مثيلات فئة "المطابق" لمطابقة تسلسلات الأحرف مع نمط معين.

Input is provided to matchers via the `CharSequence` interface in order to support matching against characters from a wide variety of input sources.

يتم توفير المدخلات للمطابقات عبر واجهة `CharSequence` من أجل دعم المطابقة مقابل الأحرف من مجموعة متنوعة من مصادر الإدخال.

String Searching: Naive Algorithm

البحث عن سلسلة: خوارزمية ساذجة

Objective: Given a pattern, find any substring of a given text that matches the pattern.

الهدف: إعطاء نمط ابحت عن أي سلسلة فرعية لنص معين تطابق النمط.

p pattern to be matched

m length of pattern p (characters)

t the text to be searched

n length of t (characters)

The naive algorithm examines the characters of t in sequence.

تفحص الخوارزمية الساذجة أحرف t بالتسلسل.

for j from 1 to n-m+1

if character j of t matches the first character of p

(compare following characters of t and p until a

complete match or a difference is found)

String Searching:

Knuth-Morris-Pratt Algorithm

البحث عن السلاسل: خوارزمية Knuth-Morris-Pratt

Concept: The naive algorithm is modified, so that whenever a partial match is found, it may be possible to advance the character index, j , by more than 1.

المفهوم: يتم تعديل الخوارزمية الساذجة بحيث كلما تم العثور على تطابق جزئي قد يكون من الممكن زيادة فهرس الحرف j بأكثر من 1.

Example:

```
p = "university"
t = "the uniform commercial code ..."
      ↑
      |
j=5   | after partial match continue here
```

To indicate how far to advance the character pointer, p is preprocessed to create a table, which lists how far to advance against a given length of partial match.

In the example, j is advanced by the length of the partial match, 3

للإشارة إلى مدى تقدم مؤشر الحرف p تتم معالجة p مسبقاً لإنشاء جدول يسرد مدى التقدم مقابل طول معين من المطابقة الجزئية.

في المثال تقدم j بطول المطابقة الجزئية 3..

Signature Files: Sequential Search without Inverted File

ملفات التوقيع: البحث المتسلسل بدون ملف مقلوب

Inexact filter: A quick test which discards many of the non-qualifying items. Uses the concept of a **Bloom filter**.

مرشح غير دقيق: اختبار سريع يتجاهل العديد من العناصر غير المؤهلة. يستخدم مفهوم مرشح بلوم.

Advantages

- Much faster than full text scanning -- 1 or 2 orders of magnitude
- Modest space overhead -- 10% to 15% of file
- Insertion is straightforward

مزايا

- أسرع بكثير من مسح النص الكامل - طلب واحد أو طلبيتين من حيث الحجم
- مساحة متواضعة - 10% إلى 15% من الملف
- الإدخال سهل ومباشر

Disadvantages

- Sequential searching is no good for very large files
- Some hits are false hits

سلبيات

- لا يفيد البحث المتسلسل في الملفات الكبيرة جداً
- بعض الضربات هي ضربات كاذبة

Signature Files

ملفات التوقيع

Signature size. Number of bits in a signature, F .

Word signature. A bit pattern of size F with m bits set to 1 and the others 0.

The word signature is calculated by a hash function.

Block. A sequence of text that contains D distinct words.

Block signature. The logical or of all the word signatures in a block of text.

Signature Files

ملفات التوقيع

Example

Word Signature	
free	001 000 110 010
text	000 010 101 001
block signature 001 010 111 011	

F = 12 bits in a
signature

m = 4 bits per word

D = 2 words per block

Signature Files

ملفات التوقيع

A query term is processed by matching its signature against the block signature.

تتم معالجة مصطلح الاستعلام عن طريق مطابقة توقيعه مع توقيع الكتلة.

- (a) If the term is in the block, its word signature will always match the block signature.
- (b) إذا كان المصطلح موجودا في الكتلة فإن توقيعه بالكلمة سيتطابق دائما مع توقيع الكتلة.
- (b) A word signature may match the block signature, but the word is not in the block. This is a false hit.

ب) قد يتطابق توقيع الكلمة مع توقيع الكتلة لكن الكلمة ليست موجودة في الكتلة. هذه ضربة خاطئة.

The design challenge is to minimize the false drop probability, F_d .

يتمثل التحدي في التصميم في تقليل احتمال السقوط الخاطئ F_d .

Frake, Section 4.2, page 47 discussed how to minimize F_d . The rest of this chapter discusses enhancements to the basic algorithm.

String Matching

مطابقة السلسلة

Find File: Find all files whose name includes the string **q**.

البحث عن ملف: ابحث عن جميع الملفات التي يتضمن اسمها السلسلة **q**.

Simple algorithm: Build an inverted index of all substrings of the file names of the form ***f**,

خوارزمية بسيطة: إنشاء فهرس مقلوب لجميع السلاسل الفرعية لأسماء الملفات بالشكل **f ***

Example: if the file name is **foo.txt**, search terms are:

مثال: إذا كان اسم الملف هو **foo.txt** فإن مصطلحات البحث هي:

foo.txt
oo.txt
o.txt
.txt
txt
xt
t

Lexicographic processing allows searching by any **q**.

تسمح المعالجة المعجمية بالبحث عن طريق أي **ف**.

Search for Substring

ابحث عن سلسلة فرعية

In some information retrieval applications, any substring can be a search term.

في بعض تطبيقات استرجاع المعلومات يمكن أن تكون أي سلسلة فرعية مصطلح بحث.

Tries, using **suffix trees**, provide lexicographical indexes for all the substrings in a document or set of documents.

تحاول باستخدام أشجار اللواحق توفير فهارس معجمية لجميع السلاسل الفرعية في مستند أو مجموعة من المستندات.

Tries: Search for Substring

يحاول: البحث عن سلسلة فرعية

Basic concept

The text is divided into unique semi-infinite strings, or **sistrings**. Each sistring has a starting position in the text, and continues to the right until it is unique.

مبدأ اساسي

ينقسم النص إلى سلاسل أو سلاسل فريدة شبه لا نهائية. كل سلسلة لها موضع بداية في النص وتستمر إلى اليمين حتى تصبح فريدة.

The sistrings are stored in (the leaves of) a tree, the **suffix tree**. Common parts are stored only once.

يتم تخزين الحلقات في (أوراق) شجرة شجرة اللاحقة. يتم تخزين الأجزاء المشتركة مرة واحدة فقط.

Each sistring can be associated with a location within a document where the sistring occurs. Subtrees below a certain node represent all occurrences of the substring represented by that node.

يمكن إقران كل تسلسل بموقع داخل المستند حيث يحدث التسلسل. تمثل الأشجار الفرعية الموجودة أسفل عقدة معينة جميع تكرارات السلسلة الفرعية التي تمثلها تلك العقدة.

Suffix trees have a size of the same order of magnitude as the input documents.


تمتلك أشجار اللاحقة حجمًا من نفس حجم مستندات الإدخال.

Tries: Suffix Tree

يحاول: شجرة لاحقة

Example: suffix tree for
the following words:

begin
beginning
between
bread
break



Tries: Sistrings

يحاوّل: سيسترينجس

A binary example

String: 01 100 100 010 111

Sistrings: 1 01 100 100 010 111

2 11 001 000 101 11

3 10 010 001 011 1

4 00 100 010 111

5 01 000 101 11

6 10 001 011 1


7 00 010 111

8 00 101 11



Tries: Lexical Ordering


يحاول: ترتيب معجمي



Unique string indicated in blue


Trie: Basic Concept

Trie: المفهوم الأساسي



Patricia Tree

باتريشيا تري



Single-descendant nodes are eliminated.

Nodes have bit number.