

CS 430 / INFO 430


Information Retrieval

Lecture 08

Query Refinement
(Modification):
Relevance Feedback
Information Filtering

Query Refinement

تنقيح الاستعلام



EXIT

Reformulation of Query

إعادة صياغة الاستعلام

Manual

- Add or remove search terms
- Change Boolean operators
- Change wild cards

يدوي

- إضافة أو إزالة مصطلحات البحث
- تغيير عوامل التشغيل المنطقية
- تغيير بطاقات البدل

Automatic

Change the query vector:

- Remove/add search terms
- Change weighting of search terms

تلقائي

تغيير متجه الاستعلام:

- إزالة / إضافة مصطلحات البحث
- تغيير ترجيح مصطلحات البحث

Manual Reformulation: Vocabulary Tools

إعادة الصياغة اليدوية: أدوات المفردات

Feedback to user

- Information about stop lists, stemming, etc.
- Numbers of hits on each term or phrase

ملاحظات للمستخدم

- معلومات حول قوائم الإيقاف والاشتقاق إلخ.
- عدد مرات الوصول إلى كل مصطلح أو عبارة

Suggestions to user

- Thesaurus
- Browse lists of terms in the inverted index
- Controlled vocabulary

اقتراحات للمستخدم

- القاموس الموسوعي للمفردات
- تصفح قوائم المصطلحات في الفهرس المقلوب
- السيطرة على المفردات

Manual Reformulation: Document Tools

إعادة الصياغة اليدوية: أدوات المستند

Feedback to user consists of document excerpts or surrogates

تتكون التعليقات على المستخدم من مقتطفات من المستندات أو بدائل

- Shows the user how the system has interpreted the query

يوضح للمستخدم كيف فسر النظام الاستعلام

Effective at suggesting how to restrict a search

فعالة في اقتراح كيفية تقييد البحث

- Shows examples of false hits

يظهر أمثلة من الضربات الكاذبة

Less good at suggesting how to expand a search

ليس جيداً في اقتراح كيفية توسيع البحث

- No examples of missed items

• لا توجد أمثلة للعناصر المفقودة

Relevance Feedback: Document Vectors as Points on a Surface

ملاحظات الملاءمة: متجهات المستند كنقاط على السطح

- Normalize all document vectors to be of length 1

تطبيع جميع متجهات المستند لتكون بطول 1

- Then the ends of the vectors all lie on a surface with unit radius

ثم تقع نهايات المتجهات على سطح بوحدة نصف قطرها


- For similar documents, we can represent parts of this surface as a flat region

• بالنسبة للمستندات المماثلة يمكننا تمثيل أجزاء من هذا السطح كمنطقة مسطحة

- Similar document are represented as points

Relevance Feedback: Results of a Search


ملاحظات الملاءمة: نتائج البحث



x documents found by search
query

Relevance Feedback (Concept)

تعليقات الملاءمة (المفهوم)



x documents identified by user as non-relevant

المستندات التي حددها المستخدم على أنها غير ذات صلة x

o documents identified by user as relevant

المستندات التي حددها المستخدم على أنها ذات صلة o

- original query

-

reformulated query


الاستعلام الأصلي

استعلام معاد صياغته

Theoretically Best Query

من الناحية النظرية أفضل الاستعلام

optimal
query



x non-relevant
documents

o relevant documents

Theoretically Best Query

من الناحية النظرية أفضل الاستعلام

For a specific query, q , let:

D_R be the set of all relevant documents

D_{N-R} be the set of all non-relevant documents

$\text{sim}(q, D_R)$ be the mean similarity between query q and documents in D_R

$\text{sim}(q, D_{N-R})$ be the mean similarity between query q and documents in D_{N-R}

A theoretically best query would maximize:

$$F = \text{sim}(q, D_R) - \text{sim}(q, D_{N-R})$$

Estimating the Best Query

تقدير أفضل استعلام

In practice, D_R and D_{N-R} are not known. (The objective is to find them.)

However, the results of an initial query can be used to estimate $\text{sim}(q, D_R)$ and $\text{sim}(q, D_{N-R})$.

Rocchio's Modified Query

Modified query vector

- = Original query vector
- + Mean of **relevant** documents found by original query
- Mean of **non-relevant** documents found by original query

متجه الاستعلام المعدل

= ناقل الاستعلام الأصلي

+ متوسط المستندات ذات الصلة التي تم العثور عليها من خلال
الاستعلام الأصلي

Rocchio's Modified Query

$$q_1 = q_0 + \frac{1}{n_1} \sum_{i=1}^{n_1} r_i - \frac{1}{n_2} \sum_{i=1}^{n_2} s_i$$

q_0 = vector for the initial query

q_1 = vector for the modified query

r_i = vector for relevant document i

s_i = vector for non-relevant document i

n_1 = number of relevant documents


n_2 = number of non-relevant documents

Difficulties with Relevance Feedback

الصعوبات المتعلقة بملاحظات الملاءمة

optimal
query

Hits from
the initial
query are
contained
in the gray
shaded
area



x non-relevant documents

o relevant documents

original query


▲ reformulated query

Difficulties with Relevance Feedback

الصعوبات المتعلقة بملاحظات الملاءمة

optimal
results
set

What
region
provides
the
optimal
results set?



x non-relevant documents

o relevant documents

original query

▲ reformulated query

Effectiveness of Relevance Feedback

فعالية ملاحظات الملاءمة

Best when:

الأفضل عندما:

- Relevant documents are tightly clustered (similarities are large)
يتم تجميع المستندات ذات الصلة بإحكام (أوجه التشابه كبيرة)
- Similarities between relevant and non-relevant documents are small
أوجه التشابه بين الوثائق ذات الصلة وغير ذات الصلة صغيرة

Machine Learning: Algorithms

تعلم الآلة: الخوارزميات

The choice of algorithms is a subject of active research, which is covered in several courses, notably CS 478 and CS/INFO 630.

Some effective methods include:

اختيار الخوارزميات هو موضوع بحث نشط وهو موضوع في عدة دورات
ولا سيما CS 478 و CS / INFO 630.

تتضمن بعض الطرق الفعالة ما يلي:

Naive Bayes

Rocchio Algorithm

C4.5 Decision Tree

k-Nearest Neighbors

Support Vector Machine