

CS 430 / INFO 430

Information Retrieval

Lecture 09

Latent Semantic Indexing

Course Administration

Latent Semantic Indexing

الفهرسة الدلالية الكامنة

Objective

Replace indexes that use **sets of index terms** by indexes that use **concepts**.

هدف

استبدال الفهارس التي تستخدم مجموعات من مصطلحات الفهرس بالفهارس التي تستخدم المفاهيم.

Approach

Map the term vector space into a lower dimensional space, using singular value decomposition.

يقترَب

ارسم مصطلح فضاء متجه إلى مساحة ذات بعد أقل باستخدام تحليل القيمة المفردة.

Each dimension in the new space corresponds to a latent concept in the original data.

يتوافق كل ب عد في المساحة الجديدة مع مفهوم كامن في البيانات الأصلية.

Latent = hidden

Deficiencies with Conventional Automatic Indexing

أوجه القصور في الفهرسة التلقائية التقليدية

Synonymy: Various words and phrases refer to the same concept (lowers recall).

مرادف: تشير الكلمات والعبارات المختلفة إلى نفس المفهوم (يقلل من التذكر).

Polysemy: Individual words have more than one meaning (lowers precision)

تعدد المعاني: الكلمات الفردية لها أكثر من معنى (دقة أقل)

Independence: No significance is given to two terms that frequently appear together

الاستقلال: لا توجد أهمية لمصطلحين يظهران معاً بشكل متكرر

Latent semantic indexing addresses the first of these (synonymy), and the third (dependence)

تتناول الفهرسة الدلالية الكامنة أولهما (مرادف) والثالث (التبعية)

Example

مثال

Query: "IDF in computer-based information look-up"

الاستعلام: "جيش الدفاع الإسرائيلي في البحث عن المعلومات المستندة إلى الكمبيوتر"

Index terms for a document: access, document, retrieval,
indexing

مصطلحات الفهرس للمستند: الوصول المستند الاسترجاع الفهرسة

How can we recognize that information look-up is related to retrieval and indexing?

كيف يمكننا التعرف على أن البحث عن المعلومات مرتبط بالاسترجاع والفهرسة

Conversely, if information has many different contexts in the set of documents, how can we discover that it is an unhelpful term for retrieval?

على العكس من ذلك إذا كانت المعلومات تحتوي على العديد من السياقات المختلفة في مجموعة المستندات فكيف يمكننا اكتشاف أنها مصطلح غير مفيد للاسترجاع

Technical Memo Example: Titles

مثال على المذكرة الفنية: العناوين

c1 Human machine interface for Lab ABC computer applications

واجهة الإنسان للآلة لتطبيقات الكمبيوتر الخاصة بمختبر ABC c1

c2 A survey of user opinion of computer system response time

مسح رأي المستخدم حول وقت استجابة نظام الكمبيوتر c2

c3 The EPS user interface management system

نظام إدارة واجهة المستخدم EPS c3

c4 System and human system engineering testing of EPS

اختبار هندسة النظام والأنظمة البشرية لـ EPS c4

c5 Relation of user-perceived response time to error measurement

العلاقة بين وقت الاستجابة الذي يدركه المستخدم لقياس الخطأ c5

m1 The generation of random, binary, unordered trees

توليد أشجار عشوائية وثنائية غير مرتبة m1

m2 The intersection graph of paths in trees

رسم تقاطع المسارات في الأشجار m2

m3 Graph minors IV: Widths of trees and well-quasi-ordering

م 3 الرسم البياني القصر الرابع: عرض الأشجار وشبه جيدة الترتيب

m4 Graph minors: A survey

Technical Memo Example: Terms and Documents

مثال على المذكرة الفنية: الشروط والمستندات

Terms			Documents											
c1	c2	c3	c4	c5	m1	m2	m3	m4						
human	1	0	0	1	0	0	0	0						
interface	1	0	1	0	0	0	0	0						
computer	1	1	0	0	0	0	0	0						
user	0	1	1	0	1	0	0	0						
system	0	1	1	2	0	0	0	0						
response	0	1	0	0	1	0	0	0						
time	0	1	0	0	1	0	0	0						
EPS	0	0	1	1	0	0	0	0						
survey	0	1	0	0	0	0	0	0	1					
trees	0	0	0	0	0	1	1	1	0					
graph	0	0	0	0	0	0	1	1	1					
minors	0	0	0	0	0	0	0	1	1					

Technical Memo Example: Query

مثال على المذكرة الفنية: استعلام

Query:

Find documents relevant to "human computer interaction"

استفسار:

البحث عن المستندات ذات الصلة بـ "التفاعل البشري مع الكمبيوتر"

Simple Term Matching:

Matches c1, c2, and c4

Misses c3 and c5

مطابقة المصطلحات البسيطة:

يطابق c1 و c2 و c4

يخطئ c3 و c5

Models of Semantic Similarity

نماذج التشابه الدلالي

Proximity models: Put similar items together in some space or structure

النماذج المتقاربة: ضع العناصر المتشابهة معاً في مساحة أو بنية ما

- Clustering (hierarchical, partition, overlapping). Documents are considered close to the extent that they contain the same terms. Most then arrange the documents into a hierarchy based on distances between documents.

التجميع (الهرمي) التقسيم التداخل (تعتبر المستندات قريبة من الحد الذي تحتوي عليه المصطلحات نفسها). يقوم معظمهم بعد ذلك بترتيب المستندات في تسلسل هرمي بناءً على المسافات بين المستندات.

- Factor analysis based on matrix of similarities between documents (single mode).

• تحليل عامل يعتمد على مصفوفة أوجه التشابه بين المستندات (الوضع الفردي).

Selection of Two-Mode Factor Analysis

اختيار تحليل عامل ثنائي الوضع

Additional criterion:

Computationally efficient $O(N^2k^3)$

N is number of terms plus documents

k is number of dimensions

معييار إضافي:

كفاءة حسابية $O(N^2k^3)$

هو عدد المصطلحات بالإضافة إلى المستندات N

ك هو عدد الأبعاد

The term vector space

مصطلح متجه الفضاء

The space has as many dimensions as there are terms in the word list.

تحتوي المساحة
على العديد من
الأبعاد حيث
توجد مصطلحات
في قائمة
الكلمات.





Figure 1

Latent
concept
vector space

- term
- document
- query
- cosine > 0.9



Mathematical concepts

مفاهيم رياضية

Define X as the term-document matrix, with t rows (number of index terms) and d columns (number of documents).

د X كمصفوفة مصطلح المستند مع صفوف t عدد مصطلحات الفهرس (وأعمدة d) عدد المستندات).

Singular Value Decomposition

تحليل القيمة الفردية

For any matrix X , with t rows and d columns, there exist matrices T_0 , S_0 and D_0' , such that:

$$X = T_0 S_0 D_0'$$

مصفوفة X مع صفوف t وأعمدة d توجد مصفوفات T_0 و S_0 و D_0' مثل:

$$X = T_0 S_0 D_0'$$

T_0 and D_0 are the matrices of left and right singular vectors

D_0 هي مصفوفات متجهات المفرد الأيمن والأيسر T_0

T_0 and D_0 have orthonormal columns

يحتوي T_0 و D_0 على أعمدة متعامدة

S_0 is the diagonal matrix of singular values

هي المصفوفة القطرية للقيم المفردة S_0

Dimensions of matrices


أبعاد المصفوفات

$$\begin{array}{ccccccc} t \times d & & t \times m & & m \times m & & m \times d \\ \boxed{X} & = & \boxed{T_0} & & \boxed{S_0} & & \boxed{D_0'} \end{array}$$

m is the rank of X $< \min(t, d)$

Selection of singular values

اختيار القيم الفردية



k is the number of singular values chosen to represent the concepts in the set of documents.

Usually, $k \ll m$.

Experimental Results

Deerwester, et al. tried latent semantic indexing on two test collections, MED and CISI, where queries and relevant judgments were available.

ديروستر وآخرون. جرب الفهرسة الدلالية الكامنة في مجموعتين للاختبار MED و CISI حيث توفرت الاستفسارات والأحكام ذات الصلة.

Documents were full text of title and abstract.

كانت الوثائق النص الكامل للعنوان والملخص.

Stop list of 439 words (SMART); no stemming, etc.

Comparison with:


(a) simple term matching, (b) SMART, (c) Voorhees method.

قائمة إيقاف من 439 كلمة (SMART) لا ينبع إلخ.
مقارنة ب:

أ) مطابقة المصطلح البسيط (ب) SMART (ج) طريقة فورهييس.

Experimental Results: 100 Factors

النتائج التجريبية: 100 عامل



Experimental Results. Number of Factors

النتائج التجريبية: عدد العوامل

MED - Precision as a Function of Number of Factors

