

CS 430 / INFO 430

Information Retrieval

Lecture 10

Evaluation of Retrieval Effectiveness

1

Studies of Retrieval Effectiveness

دراسات فعالية الاسترجاع

- [The Cranfield Experiments](#), Cyril W. Cleverdon, Cranfield College of Aeronautics, 1957 -1968

The Cranfield Experiments Cyril W. Cleverdon Cranfield College of Aeronautics 1957-1968

- [SMART System](#), Gerald Salton, Cornell University, 1964-1988

نظام سمارت جيرالد سالتون جامعة كورنيل 1964-1988

- [TREC](#), Donna Harman and Ellen Voorhees, National Institute of Standards and Technology (NIST), 1992 –

- TREC دونا هارمان وإلين فورهييس المعهد الوطني للمعايير والتكنولوجيا (NIST) 1992 -

Matching: Recall and Precision

المطابقة: استدعاء ودقة

With **matching methods**, if information retrieval were perfect ...

مع طرق المطابقة إذا كان استرجاع المعلومات مثالي ...

Every hit would be relevant to the original query, and every relevant item in the body of information would be found.

ستكون كل نتيجة ذات صلة بالاستعلام الأصلي وسيتم العثور على كل عنصر ذي صلة في نص المعلومات.

Precision: fraction (or percentage) of the hits that are relevant, i.e., the extent to which the set of hits retrieved by a query satisfies the requirement that generated the query.

الدقة: جزء) أو نسبة مئوية (من النتائج ذات الصلة أي مدى استيفاء مجموعة النتائج التي تم استردادها بواسطة طلب البحث للمتطلبات التي أدت إلى إنشاء طلب البحث.

Recall: fraction (or percentage) of the relevant items that are found by the query, i.e., the extent to which the query found all the items that satisfy the requirement.

استدعاء: جزء) أو نسبة مئوية (من العناصر ذات الصلة التي تم العثور عليها بواسطة الاستعلام أي مدى العثور على جميع العناصر التي تفي بالمتطلبات.

Recall and Precision with Exact Matching

استدعاء ودقة مع المطابقة التامة

Example

مثال

- Corpus of 10,000 documents, 50 on a specific topic
- مجموعة من 10000 وثيقة 50 حول موضوع معين
- Ideal search finds these 50 documents and reject all others
- يعثر البحث المثالي على هذه المستندات الخمسين ويرفض جميع المستندات الأخرى
- Actual search identifies 25 documents; 20 are relevant but 5 were on other topics

Measuring Precision and Recall

قياس الدقة والاستدعاء

Precision is easy to measure:

- الدقة سهلة القياس:
- A knowledgeable person looks at each document that is identified and decides whether it is relevant.
- ينظر الشخص المطلع إلى كل وثيقة يتم تحديدها ويقرر ما إذا كانت ذات صلة.
- In the example, only the 25 documents that are found need to be examined.
- في المثال لا يلزم فحص سوى 25 وثيقة تم العثور عليها.

Recall is difficult to measure:

- من الصعب قياس التذكر:
- To know all relevant items, a knowledgeable person must go through the entire collection, looking at every object to decide if it fits the criteria.
- لمعرفة جميع العناصر ذات الصلة يجب على الشخص المطلع مراجعة المجموعة بأكملها والنظر في كل كائن ليقرر ما إذا كان يناسب المعايير.
- In the example, all 10,000 documents must be examined.
- في المثال يجب فحص جميع المستندات البالغ عددها 10000.

Ranking Methods: Precision and Recall

طرق الترتيب: الدقة والاستدعاء

Precision and recall are defined for a fixed set of hits, e.g., Boolean retrieval.

يتم تحديد الدقة والاستدعاء لمجموعة ثابتة من النتائج على
سبيل المثال استرجاع منطقي.

Their use needs to be modified for a ranked list of results.

يحتاج استخدامها إلى تعديل للحصول على قائمة مرتبة بالنتائج.

Ranking Methods

طرق الترتيب

Precision and recall measure the results of a **single query** using a **specific search system** applied to a **specific set of documents**.

تقيس الدقة والاستدعاء نتائج استعلام واحد باستخدام نظام بحث محدد مطبق على مجموعة محددة من المستندات.

Matching methods:

طرق المطابقة:

Precision and recall are single numbers.

الدقة والاستدعاء أرقام مفردة.

Ranking methods:

طرق الترتيب:

Precision and recall are functions of the rank order.

الدقة والاستدعاء من وظائف ترتيب الرتبة.

Evaluating Ranking: Recall and Precision

تقييم الترتيب: الاستدعاء والدقة

If information retrieval were perfect ...

إذا كان استرجاع المعلومات مثالي ...

Every document relevant to the original information need would be **ranked** above every other document.

سيتم تصنيف كل وثيقة ذات صلة بالمعلومات الأصلية المطلوبة فوق كل وثيقة أخرى.

With ranking, precision and recall are **functions of the rank** order.

مع الترتيب والدقة والاستدعاء من وظائف ترتيب الترتيب.

Precision(n): fraction (or percentage) of the n most highly ranked documents that are relevant.

الدقة (n): (جزء) أو نسبة مئوية (من أكثر الوثائق مرتبة ذات الصلة).

Recall(n): fraction (or percentage) of the relevant items that are in the n most highly ranked documents.

استدعاء (n): (كسر) أو نسبة مئوية (من العناصر ذات الصلة الموجودة في الوثائق n الأكثر مرتبة).

Precision and Recall with Ranking

الدقة والاستدعاء مع الترتيب

Example

"Your query found 349,871 possibly relevant documents.
Here are the first eight."

Examination of the first 8 finds that 5 of them are relevant.

مثال

"عثر طلب البحث على 349871 وثيقة من المحتمل أن تكون ذات صلة.
ها هي الثمانية الأولى."


وجد فحص أول 8 أن 5 منهم ذات صلة.

Graph of Precision with Ranking: $P(r)$

رسم بياني للدقة مع الترتيب: $P(r)$

Relevant? Y N Y Y N Y N Y

Precision
 $P(r)$



Ranked retrieval: Recall and precision after retrieval of n documents

الاسترجاع المصنف: الاسترجاع والدقة بعد استرجاع عدد n من المستندات

n	relevant	recall	precision
---	----------	--------	-----------

1	yes	0.2	1.0
---	-----	-----	-----

2	yes	0.4	1.0
---	-----	-----	-----

3	no	0.4	0.67
---	----	-----	------

4	yes	0.6	0.75
---	-----	-----	------

5	no	0.6	0.60
---	----	-----	------

6	yes	0.8	0.67
---	-----	-----	------

7	no	0.8	0.57
---	----	-----	------

8	no	0.8	0.50
---	----	-----	------

9	no	0.8	0.44
---	----	-----	------

10	no	0.8	0.40
----	----	-----	------

11	no	0.8	0.36
----	----	-----	------

12	no	0.8	0.33
----	----	-----	------

13	yes	1.0	0.38
----	-----	-----	------


14	no	1.0	0.36
----	----	-----	------

SMART system using
Cranfield data, 200
documents in
aeronautics of which 5
are relevant

نظام SMART باستخدام
بيانات 200 Cranfield
وثيقة في مجال الطيران منها
وثيقة ذات صلة 5

Precision-recall graph

رسم بياني لاستدعاء الدقة



11 Point Precision (Recall Cut Off) دقة 11 نقطة (قطع استدعاء)

$p(n)$ is precision at that point where recall has first reached n

Define 11 standard recall points $p(r_0), p(r_1), \dots p(r_{10})$,
where $p(r_j) = p(j/10)$

Note: if $p(r_j)$ is not an exact data point, use interpolation

هي الدقة في تلك النقطة التي وصل فيها الاستدعاء إلى n لأول مرة $p(n)$
حدد 11 نقطة استدعاء قياسية $p(r_0) \ p(r_1) \ \dots \ p(r_{10})$
حيث $p(r_j) = p(j / 10)$

ملاحظة: إذا لم تكن $p(r_j)$ نقطة بيانات دقيقة فاستخدم الاستيفاء

Example: SMART System on Cranfield Data

مثال: نظام SMART على بيانات كرانفيلد

Recall	Precision
0.0	1.0
0.1	1.0
0.2	1.0
0.3	1.0
0.4	1.0
0.5	0.75
0.6	0.75
0.7	0.67
0.8	0.67
0.9	0.38
1.0	0.38

Precision values in blue are actual data.


Precision values in red are by interpolation (by convention equal to the next actual data value).

قيم الدقة باللون الأزرق هي بيانات فعلية.

قيم الدقة باللون الأحمر هي عن طريق الاستيفاء (حسب الاصطلاح يساوي قيمة البيانات الفعلية التالية).

Recall cutoff graph: choice of interpolation points

استدعاء الرسم البياني للقطع: اختيار نقاط الاستيفاء



Average precision

متوسط الدقة

Average precision for a single topic is the mean of the precision obtained after each relevant document is obtained.

متوسط الدقة لموضوع واحد هو متوسط الدقة التي تم الحصول عليها بعد الحصول على كل مستند ذي صلة.

Example:

مثال:

$$p = (1.0 + 1.0 + 0.75 + 0.67 + 0.38) / 5 \\ = 0.75$$

$$1.0 + 1.0 + 0.75 + 0.67 + 0.38) / 5 = 0.75 (= \text{ع})$$

Mean average precision for a run consisting of many topics is the mean of the average precision scores for each individual topic in the run.

متوسط الدقة للتشغيل المكون من العديد من الموضوعات هو متوسط درجات الدقة لكل موضوع فردي في السباق.

Definitions from TREC-8

تعريف من TREC-8

Relevance

ملاءمة

Recall and precision: depend on concept of relevance

لاستدعاء والدقة: يعتمدان على مفهوم الصلة

Relevance is a context-, task-dependent property of documents

الصلة هي خاصية تعتمد على السياق والمهمة للمستندات

"Relevance is the correspondence in context between an information requirement statement ... and an article (a document), that is, the extent to which the article covers the material that is appropriate to the requirement statement."

"الملاءمة هي المراسلات في السياق بين بيان متطلبات المعلومات ... ومقال (مستند) أي مدى تغطية المقالة للمادة المناسبة لبيان المتطلبات."

F. W. Lancaster, 1979

Relevance

ملاءمة

How stable are relevance judgments?

ما مدى استقرار الأحكام ذات الصلة

- For textual documents, knowledgeable users have good agreement in deciding whether a document is relevant to an information requirement.
• بالنسبة للمستندات النصية يكون لدى المستخدمين المطلعين اتفاق جيد في تقرير ما إذا كانت الوثيقة ذات صلة بمتطلبات المعلومات.
- There is less consistency with non-textual documents, e.g., a photograph.
• هناك تناسق أقل مع المستندات غير النصية مثل الصور الفوتوغرافية.
- Attempts to have users give a level of relevance, e.g., on a five point scale, are inconsistent.
• محاولات حث المستخدمين على إعطاء مستوى من الملاءمة على سبيل المثال على مقياس من خمس نقاط غير متسقة.

Relevance judgments (TREC)

الأحكام ذات الصلة (TREC)

- In the TREC-1 experiments, each topic was judged by a single assessor, who also set the topic statement.
• في تجارب TREC-1 تم الحكم على كل موضوع بواسطة مقيم واحد والذي قام أيضاً بتعيين بيان الموضوع.
- In TREC-2, a sample of the topics and documents was rejudged by second expert assessor. The average agreement was about 80%.
• في TREC-2 تمت إعادة الحكم على عينة من الموضوعات والوثائق من قبل خبير تقييم ثانٍ. كان متوسط الاتفاق حوالي 80%.
- In TREC-4, all topics were rejudged by two additional assessors, with 72% agreement among all three assessors.
• في TREC-4 تمت إعادة الحكم على جميع الموضوعات من قبل مقيمين إضافيين مع موافقة 72% بين جميع المقيمين الثلاثة.

Relevance judgments (TREC)

الأحكام ذات الصلة (TREC)

However:

لكن:

- In the TREC-4 tests, most of the agreement was among the documents that all assessors agreed were non-relevant
- في اختبارات TREC-4 كان معظم الاتفاق من بين الوثائق التي اتفق جميع المقيمين على أنها غير ذات صلة
- 30% of documents judged relevant by the first assessor, were judged non-relevant by both additional assessors.
- من الوثائق التي اعتبر المقيم الأول أنها ذات صلة بالموضوع اعتبرها المقيمون الإضافيون 30% غير ذات صلة.

Using data from TREC-4 and TREC-6, Voorhees estimates a practical upper bound of 65% precision at 65% recall, as the level at which human experts agree with one another.

باستخدام بيانات من TREC-4 و TREC-6 يقدر فورهييس الحد الأعلى العملي للدقة بنسبة 65% عند استدعاء 65% وهو المستوى الذي يتفق عنده الخبراء البشريون مع بعضهم البعض.

Relevance as a Set Comparison


الصلة كمقارنة مجموعة

D = set of documents

D = مجموعة من الوثائق

A = set of documents that satisfy some user-based criterion

B = set of documents identified by the search system



A = مجموعة من المستندات التي تفي ببعض المعايير المعتمدة على المستخدم

B = مجموعة من الوثائق التي تم تحديدها بواسطة نظام البحث

Measures based on relevance

التدابير على أساس الصلة

$$\text{recall} = \frac{\text{retrieved relevant}}{\text{relevant}} = \frac{|A \cap B|}{|A|}$$

$$\text{precision} = \frac{\text{retrieved relevant}}{\text{retrieved}} = \frac{|A \cap B|}{|B|}$$


$$\text{fallout} = \frac{\text{retrieved not-relevant}}{\text{not-relevant}} = \frac{|B - A|}{|D - A|}$$

Combining Recall and Precision: Normalized Symmetric Difference

الجمع بين الاسترجاع والدقة: فرق تماثل معياري

Symmetric Difference: The set of elements belonging to one but not both of two given sets.

فرق تماثل: مجموعة العناصر التي تنتمي إلى مجموعة واحدة وليس كليهما من مجموعتين معيّنتين.




Symmetric difference, $S = A \cup B - A \cap B$

Normalized symmetric difference = $|S| / 2 (|A| + |B|)$

$$= \frac{1}{2} \left\{ 1 - \frac{1}{(1/\text{recall} + 1/\text{precision})} \right\}$$

Normalized recall measure

قياس الاسترجاع الطبيعي



Normalized recall

استدعاء طبيعي

Normalized recall = $\frac{\text{area between actual and worst}}{\text{area between best and worst}}$

$$R_{\text{norm}} = 1 - \frac{\sum_{i=1}^n r_i - \sum_{i=1}^n i}{n(N - n)} \quad \text{(after some mathematical manipulation)}$$

Cranfield Collection

مجموعة كرانفيلد

The first Information Retrieval test collection

أول مجموعة اختبار استرداد المعلومات

Test collection:

1,400 documents on aerodynamics

مجموعة الاختبار:

وثيقة عن الديناميكا الهوائية 1400

Queries:

225 queries, with a list of the documents that should be retrieved for each query

استفسارات:

استعلام ١ مع قائمة بالوثائق التي يجب استرجاعها لكل استعلام 225

Cranfield Second Experiment

تجربة كرانفيلد الثانية

Comparative efficiency of indexing systems:

الكفاءة النسبية لأنظمة الفهرسة:

(Universal Decimal Classification, alphabetical subject index, a special facet classification, Uniterm system of co-ordinate indexing)

(التصنيف العشري العالمي فهرس الموضوع الأبجدي تصنيف الأوجه الخاص نظام يونيتيرم للفهرسة التنسيقية)

Four indexes prepared manually for each document in three batches of 6,000 documents -- total 18,000 documents, each indexed four times. The documents were reports and paper in aeronautics.

أربعة فهرس معدة يدوي لكل مستند في ثلاث دفعات من 6000 مستند - إجمالي 18000 مستند كل منها مفهرسة أربع مرات. كانت الوثائق تقارير وورقة في علم الطيران.

Indexes for testing were prepared on index cards and other cards.

تم إعداد فهرس للاختبار على بطاقات فهرسة وبطاقات أخرى.

Very careful control of indexing procedures.

مراقبة دقيقة للغاية لإجراءات الفهرسة.

Cranfield Second Experiment (continued)

تجربة كرانفيلد الثانية)تابع)

Searching:

يبحث:

- 1,200 test questions, each satisfied by at least one document
 - سؤال اختبار كل استيفاء بمستند واحد على الأقل 1200
- Reviewed by expert panel
 - تمت مراجعته من قبل لجنة الخبراء
- Searches carried out by 3 expert librarians
 - تم إجراء عمليات البحث بواسطة 3 أمناء مكتبات خبراء
- Two rounds of searching to develop testing methodology
 - جولتان من البحث لتطوير منهجية الاختبار
- Subsidiary experiments at English Electric Whetstone Laboratory and Western Reserve University
 - تجارب فرعية في مختبر إنجليش إليكتريك ويتستون وجامعة ويسترن ريزيرف

The Cranfield Data

بيانات كرانفيلد

The Cranfield data was made widely available and used by other researchers

تم توفير بيانات كرانفيلد على نطاق واسع واستخدامها من قبل باحثين آخرين

- Salton used the Cranfield data with the SMART system (a) to study the relationship between recall and precision, and (b) to compare automatic indexing with human indexing

• استخدم سالتون بيانات كرانفيلد مع نظام SMART (أ) لدراسة العلاقة بين الاستدعاء والدقة (و ب) لمقارنة الفهرسة التلقائية بالفهرسة البشرية

- Sparc Jones and van Rijsbergen used the Cranfield data for experiments in relevance weighting, clustering, definition of test corpora, etc.

• استخدم Sparc Jones و van Rijsbergen بيانات Cranfield لإجراء تجارب في ترجيح الصلة بالموضوع والتجميع وتعريف مجموعات الاختبار وما إلى ذلك.

Cranfield Experiments -- Measures of Effectiveness for Matching Methods

تجارب كرانفيلد - مقاييس فعالية طرق المطابقة

Cleverdon's work was applied to matching methods. He made extensive use of recall and precision, based on concept of relevance.


تم تطبيق عمل Cleverdon على طرق المطابقة. لقد استخدم على نطاق واسع الاستدعاء والدقة بناء على مفهوم الصلة.

precision (%)

Each x represents one search.
The graph illustrates the trade-off between precision and recall.


كل س يمثل بحث واحد. يوضح الرسم البياني المفاضلة بين الدقة والاستدعاء.

recall (%)



Typical precision-recall graph for different queries

رسم بياني نموذجي لاستدعاء الدقة لاستعلامات مختلفة



A Crucial Cranfield Results

نتائج حاسمة كرانفيلد

- The various manual indexing systems have similar retrieval efficiency
تتمتع أنظمة الفهرسة اليدوية المختلفة بكفاءة استرجاع متشابهة
- Retrieval effectiveness using automatic indexing can be at least as effective as manual indexing with controlled vocabularies
• فاعلية الاسترجاع باستخدام الفهرسة التلقائية يمكن أن تكون على الأقل بنفس فعالية الفهرسة اليدوية باستخدام المفردات التي يتم التحكم فيها
- > original results from the Cranfield + SMART experiments
(published in 1967)
> النتائج الأصلية من تجارب Cranfield + SMART نشرت عام 1967
- > considered counter-intuitive
> يعتبر غير بديهي
- > other results since then have supported this conclusion
> نتائج أخرى منذ ذلك الحين أكدت هذا الاستنتاج